

Modelo de machine learning para disminuir la tasa de deserción de estudiantes antiguos en centro de estudio superior

Item Type	info:eu-repo/semantics/bachelorThesis
Authors	Borjas Ramos, Neil Enrique; Saqui Marin, Carlos Jean Pierre
Publisher	Universidad Peruana de Ciencias Aplicadas (UPC)
Download date	30/03/2026 20:40:49
Item License	http://creativecommons.org/licenses/by-nc-sa/4.0/
Link to Item	http://hdl.handle.net/10757/672020



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

**PROGRAMA ACADÉMICO DE INGENIERÍA DE SISTEMAS DE
INFORMACIÓN**

**Modelo de machine learning para disminuir la tasa de deserción de
estudiantes antiguos en centro de estudio superior**

TRABAJO DE SUFICIENCIA PROFESIONAL

Para optar el título profesional de Ingeniero de Sistemas de Información

AUTOR(ES)

Borjas Ramos, Neil Enrique	0000-0002-0196-3971
Saqui Marin, Carlos Jean Pierre	0009-0003-1466-027X

ASESOR(ES)

Ramirez Garcia, Orestes Manolo	0000-0002-1653-4344
--------------------------------	---------------------

Lima, 13 de noviembre de 2023

DEDICATORIA

Dedicamos este logro a nuestros padres, cuyo amor, apoyo inquebrantable y ejemplo de sacrificio han sido la fuerza detrás de este trabajo. Cada paso en este camino de investigación y aprendizaje ha sido guiado por su constante aliento, y cada éxito que celebramos es un reflejo de su dedicación. Esta dedicatoria es un testimonio de nuestra profunda gratitud y amor hacia ellos, ya que, sin su presencia y guía, este logro y nuestro crecimiento personal no habrían sido posibles.

RESUMEN

El proyecto tiene como objetivo implementar un modelo de aprendizaje automático en centros de estudios superiores. El enfoque principal se centra en optimizar un proceso del área de experiencia estudiantil, específicamente, prediciendo el porcentaje de deserción estudiantil. Para desarrollar el proyecto, se llevó a cabo una comparación de algoritmos de aprendizaje automático, con el propósito de seleccionar el más adecuado. El diseño del modelo incluyó la creación de una tabla maestra que incorpora todas las variables como información académica actual, información académica anterior, información de boletas, ratios de asistencia, información personal e información de encuestas, junto con un análisis estadístico utilizando técnicas como WOE para identificar cuáles de estas variables contribuyen significativamente a una predicción. Las validaciones se realizaron mediante la comparación de algoritmos como RUSBoost, GausNB, Percept, LightGBM, utilizando indicadores clave como Recall mean, Precision mean y ROC AUC mean y entre otros indicadores para asegurarse de que el modelo sea efectivo y preciso. Es por ello que luego de evaluar entre todos los algoritmos el que obtuvo mayor puntaje fue LightGBM con un Recall mean de 86.37%, Precision mean de 86.83% y un ROC AUC mean de 77.61%. Además, se ha establecido un plan de continuidad para mejorar el modelo de machine learning con el tiempo. Antes de la implementación la deserción estudiantil fue del 13.45%, en el periodo 2022-1 y luego de su implementación el periodo 2023-1 esta fue de 9.45%.

Palabras clave: Aprendizaje automático, Algoritmos de Aprendizaje automático, análisis estadístico, evaluación de rendimiento.

ABSTRACT

The project aims to implement a machine learning model in higher education institutions. The main focus is on optimizing a process in the student experience area, specifically, predicting the student dropout rate. To develop the project, a comparison of machine learning algorithms was conducted with the purpose of selecting the most suitable one. The model design included creating a master table that incorporates all variables such as current academic information, past academic information, grade information, attendance ratios, personal information, and survey information, along with statistical analysis using techniques like WOE to identify which of these variables significantly contribute to a prediction. Validations were performed by comparing algorithms like RUSBoost, GausNB, Percept, LightGBM, using key indicators like Recall mean, Precision mean, ROC AUC mean, and other indicators to ensure the model is effective and accurate. Therefore, after evaluating all the algorithms, LightGBM obtained the highest score with a Recall mean of 86.37%, Precision mean of 86.83%, and ROC AUC mean of 77.61%. Additionally, a continuity plan has been established to improve the machine learning model over time. Before implementation, the student dropout rate was 13.45% in the 2022-1 period, and after implementation in the 2023-1 period, it decreased to 9.45%.

Keywords: Machine Learning, Machine Learning Algorithms, Statistical Analysis, Performance Evaluation

u201622662_ Borjas Ramos, Neil Enrique_ Modelo de machine learning para disminuir la tasa de deserción de estudiantes antiguos en centro de estudio superior

INFORME DE ORIGINALIDAD

6%	3%	1%	5%
INDICE DE SIMILITUD	FUENTES DE INTERNET	PUBLICACIONES	TRABAJOS DEL ESTUDIANTE

FUENTES PRIMARIAS

1	Submitted to Universidad Peruana de Ciencias Aplicadas Trabajo del estudiante	4%
2	Submitted to ITESM: Instituto Tecnológico y de Estudios Superiores de Monterrey Trabajo del estudiante	<1 %
3	Submitted to Universidad de Alcalá Trabajo del estudiante	<1 %
4	Submitted to Corporación Universitaria Minuto de Dios, UNIMINUTO Trabajo del estudiante	<1 %
5	www.bcn.cl Fuente de Internet	<1 %
6	es.wikipedia.org Fuente de Internet	<1 %
7	Submitted to Instituto Superior de Artes, Ciencias y Comunicación IACC Trabajo del estudiante	<1 %

TABLA DE CONTENIDOS

1	CAPÍTULO 1: DEFINICIÓN DEL PROYECTO	10
1.1	Antecedentes.....	10
1.1.1	Deserción Estudiantil: Contexto Global y Local.....	10
1.1.2	Factores Contribuyentes a la Deserción Estudiantil.....	12
1.1.3	Aprendizaje automático en la Educación Superior.....	13
1.2	Descripción de la Organización	14
1.3	Análisis del Problema	15
1.4	Objetivos.....	16
1.4.1	General.....	16
1.4.2	Específicos.....	16
1.5	Indicadores de Éxito	17
1.6	Planificación del Proyecto	17
2	CAPÍTULO 2: MARCO TEÓRICO	17
2.1	Marco Conceptual.....	17
2.2	Estándares, frameworks y buenas prácticas.....	20
2.3	Bases Legales y Marco Normativo	22
3	CAPÍTULO 3: DESARROLLO DEL PROYECTO	23
3.1	Diseño de la Solución	23
3.1.1	Análisis de tecnología para el proyecto.....	23
3.1.2	Análisis del proceso de negocio AS-IS y TO-BE.....	31
3.2	Desarrollo de la Solución.....	33
3.3	Validación del Proyecto.....	36
3.4	Interpretación de los Resultados	38

3.5	Plan de continuidad.....	39
3.5.1	Planificar (Plan):.....	39
3.5.2	Hacer (Do):	39
3.5.3	Comprobar (Check):	40
3.5.4	Actuar (Act):.....	40
4	CONCLUSIONES Y RECOMENDACIONES	41
4.1	Conclusiones.....	41
4.2	Recomendaciones	41
5	REFERENCIAS	43
6	ANEXOS.....	49
6.1	ANEXO 1	49
6.2	ANEXO 2	50
6.3	ANEXO 3	51

ÍNDICE DE TABLAS

Tabla 1	Puntuación utilizada para los benchmarking.....	23
Tabla 2	Descripción de los criterios evaluados para el benchmarking de algoritmos de aprendizaje automático.	23
Tabla 3	Tabla de priorización de criterios para el benchmarking	24
Tabla 4	Benchmarking de algoritmos de machine learning	24
Tabla 5	Descripción de los criterios evaluados para el benchmarking de lenguajes de programación orientados a aprendizaje automático	25
Tabla 6	Tabla de priorización de criterios para el benchmarking de lenguajes de programación orientados a aprendizaje automático	26
Tabla 7	Benchmarking de lenguajes de programación orientados a aprendizaje automático	26
Tabla 8	Descripción de los criterios evaluados para el benchmarking de plataformas de Business Intelligence	27
Tabla 9	Tabla de priorización de criterios para el benchmarking de plataformas de Business Intelligence	27
Tabla 10	Benchmarking de plataformas de Business Intelligence	28
Tabla 11	Descripción de los criterios evaluados para el benchmarking de bases de datos para aprendizaje profundo.....	29
Tabla 12	Tabla de priorización de criterios para el benchmarking de bases de datos para aprendizaje profundo	29
Tabla 13	Benchmarking de bases de datos para aprendizaje profundo	30
Tabla 14	Variables más importantes del modelo.....	33
Tabla 15	Comparación de algoritmo del modelo	37

ÍNDICE DE FIGURAS

Figura 1	Diagrama de Gantt de planificación del proyecto	17
Figura 2	Arquitectura lógica de datawarehouse	32
Figura 3	Dashboard de la solución del modelo predictivo	32
Figura 4	Dashboard Gerencial impacto del modelo predictivo	33
Figura 5	Variable Ciclo de estudiante (Evaluación de análisis de datos y Análisis WOE)	35
Figura 6	Variable Turno Estudio (Evaluación de análisis de datos y Análisis WOE)	35
Figura 7	Variable Ratio Asistencia Acumulado (Evaluación de análisis de datos y Análisis WOE).....	35
Figura 8	Importación del algoritmo LightGBM	36
Figura 9	Interpretación del algoritmo LighGBM	36

1 CAPÍTULO 1: DEFINICIÓN DEL PROYECTO

1.1 Antecedentes

El acceso a la educación superior se reconoce como un factor clave para el progreso socioeconómico y la movilidad social (Rivera Camargo, 2019). Sin embargo, el 42.6% de estudiantes categorizados en el nivel socioeconómico de pobreza no extrema dejaron sus estudios superiores. En contraste, en el nivel socioeconómico de no pobreza, solo el 18.1% (Dávila Morán et al., 2022) . La deserción estudiantil no solo representa una pérdida de talento y potencial individual, sino que también tiene repercusiones negativas en aspectos socioeconómicos de las comunidades y países afectados. Ante este panorama, las tecnologías emergentes, en particular el aprendizaje automático, están siendo exploradas como herramientas prometedoras para abordar y potencialmente mitigar este problema. Esta sección de antecedentes se dedica a examinar la naturaleza multifacética de la deserción estudiantil y cómo los avances en la inteligencia artificial pueden ofrecer soluciones innovadoras en el contexto peruano.

1.1.1 Deserción Estudiantil: Contexto Global y Local

- Definición y relevancia de la deserción estudiantil

La deserción estudiantil se refiere al fenómeno en el que los estudiantes deciden, por diversas circunstancias, interrumpir sus estudios antes de finalizar un programa educativo (Zárate Rueda & Mantilla Pinilla, 2014) . Este acto no es solo una pérdida de oportunidades para el estudiante, sino que también representa un reto considerable para las instituciones educativas y la sociedad en su conjunto (Vilela et al., 2021). Las causas de la deserción pueden ser multifacéticas, abarcando desde problemas socioeconómicos,

dificultades académicas hasta razones de salud o familiares (Pereira Santana & Vidal Cortez, 2020). Las consecuencias, por otro lado, son palpables tanto para las instituciones, que ven mermados sus recursos y esfuerzos, como para las sociedades que esperan formar profesionales capacitados que contribuyan al desarrollo del país (Elías et al., 2022) .

- Estadísticas y tendencias globales

La renuncia de estudiantes a seguir con su formación académica es un desafío extendido a nivel mundial, impactando naciones sin distinción de su progreso económico. Según registros del 2019, la renuncia a la educación superior alcanzó el 13% globalmente, presentando marcadas diferencias entre diversas naciones, siendo más pronunciada en aquellas en vías de desarrollo en comparación con las ya consolidadas. Por ejemplo, en África subsahariana, la tasa de abandono de la educación superior alcanza el 21%, contrastando con el 7% registrado en Europa y América del Norte (Organización de las Naciones Unidas para la Educación la Ciencia y la Cultura [UNESCO], 2020).

Existe una serie de programas y políticas que se pueden implementar para reducir la deserción estudiantil, entre ellos:

- Ampliar la entrada a la educación universitaria.
- Facilitar asistencia económica a los estudiantes.
- Mejorar el estándar de la educación superior.
- Suministrar ayudas académicas y de bienestar emocional a los estudiantes.
- Evitar la violencia en el entorno familiar.
- Colaborar con las comunidades para resolver los factores que influyen en la deserción estudiantil.

- Estadísticas y tendencias específicas para Perú

La deserción estudiantil en Perú constituye un problema significativo que influye en los estudiantes, sus familias y la sociedad en su totalidad. En el año 2019, se evidenció una tasa de deserción del 15% en la educación superior del país. Esta cifra presenta disparidades marcadas entre diversas regiones, mostrando un índice más elevado en las zonas de la selva y la sierra en contraste con la región costera.

1.1.2 Factores Contribuyentes a la Deserción Estudiantil

- Factores socioeconómicos

De acuerdo con el reporte de la Organización para la Cooperación y Desarrollo Económicos (Organización para la Cooperación y el Desarrollo Económico, 2019) , los estudiantes de entornos socioeconómicos desfavorecidos a menudo enfrentan mayores desafíos académicos, lo que puede resultar en tasas de deserción más altas. En el contexto peruano, a pesar del aumento del acceso a la educación superior en la última década, las disparidades socioeconómicas siguen representando barreras significativas para muchos estudiantes (Suzanne Worthman, 2020).

Además, otros factores como la preparación preuniversitaria, el apoyo emocional y las condiciones familiares pueden influir en la capacidad del estudiante para mantenerse en sus estudios (Tapasco Alzate et al., 2019) .

- Factores académicos y curriculares

Los factores académicos y curriculares poseen un rol significativo en la deserción universitaria en Perú. Según un informe de Sunedu, aquellos estudiantes que enfrentan desafíos académicos son más propensos a desertar. Las causas subyacentes abarcan la sensación de abrumarse por las cargas de trabajo, la pérdida de interés en la carrera elegida, la lucha por mantener un rendimiento académico adecuado, así como otros factores como la dificultad en la elección de

una carrera, la falta de motivación y apoyo académico, problemas de salud mental, experiencias de violencia familiar y desafíos en la adaptación a la vida universitaria. (Superintendencia Nacional de Educación Superior Universitaria [SUNEDU], 2021) .

1.1.3 Aprendizaje automático en la Educación Superior

- Definición y conceptos básicos de aprendizaje automático

El campo del aprendizaje automático pertenece al ámbito de la inteligencia artificial (IA), permite a las computadoras aprender y ajustarse sin requerir instrucciones de programación directa. Mediante el entrenamiento con un gran conjunto de datos, estos sistemas son capaces de reconocer patrones y tomar decisiones (Goodfellow et al., 2016) . En años recientes, un avance destacado en el campo ha sido el auge del aprendizaje profundo, que utiliza complejas redes neuronales para interpretar y procesar grandes volúmenes de datos. Estos métodos, especialmente las redes neuronales convolucionales y recurrentes, han evidenciado ser innovadores en campos como la identificación de imágenes y el procesamiento del lenguaje natural, respectivamente. (Alpaydin, 2020) .

- Aplicaciones generales de aprendizaje automático en el ámbito educativo

En el ámbito de la educación, el uso del aprendizaje automático (machine learning) se está afirmando como un recurso valioso para adaptar y mejorar los métodos de enseñanza-aprendizaje. Las investigaciones actuales destacan su capacidad para adaptar contenidos basándose en las necesidades específicas de cada estudiante, proporcionar análisis detallados a partir de grandes volúmenes de datos educativos, e innovar en la creación de recursos didácticos personalizados, tales como ejercicios prácticos y material audiovisual. Estos avances sugieren un

panorama prometedor para la integración efectiva del ML en estrategias pedagógicas contemporáneas (Hernández-Blanco et al., 2019) .

En un informe presentado en la Conferencia de la Asociación de Innovaciones Abiertas (FRUCT) de 2023, se llevó a cabo un estudio que empleó un enfoque predictivo para detectar a los alumnos con posibles probabilidades de abandonar sus estudios en universidades peruanas, así como para identificar los factores que inciden en esta situación. En este estudio, se aplicó la metodología Cross Industry Standard Process for Data Mining (CRISP-DM) para la creación del modelo, el cual se basó en el uso de cuatro algoritmos de aprendizaje automático. El experimento se realizó a una encuesta con 385 estudiantes de diversas universidades en Perú, abordando variables como edad, término académico y método de financiamiento. Los resultados señalan que la deserción universitaria está más influenciada por la edad, el término académico y el método de financiamiento del estudiante. El algoritmo Random Forest destacó con un rendimiento destacado, logrando un AUC de 0.9623 en la predicción de la deserción (Jiménez et al., 2023).

1.2 Descripción de la Organización

La entidad mencionada en este informe es una institución educativa privada de Perú con un bagaje de más de 28 años de trayectoria en la capacitación de especialistas técnicos en distintos campos. La institución ofrece una amplia gama de carreras técnicas, desde las tradicionales como Contabilidad y Administración hasta las más innovadoras como Marketing Digital y Data Science. Además, cuenta con una red de sedes ubicadas en las principales ciudades de Perú. La sede principal se encuentra en Lima, y las otras sedes se encuentran en Arequipa, Cusco, Huancayo, Iquitos, Piura, Trujillo y Villa María del Triunfo.

El centro de estudios superior posee un equipo de docentes altamente calificados, con experiencia en el sector empresarial. A través del tiempo, ha forjado acuerdos estratégicos con múltiples compañías e instituciones, facilitando a sus estudiantes el acceso a programas de prácticas profesionales y la posibilidad de encontrar empleo rápidamente tras su graduación. Dotado de una infraestructura moderna y equipado con las últimas tecnologías, la institución busca crear un entorno idóneo para la educación, la investigación y el desarrollo de ideas innovadoras.

En términos organizativos, el instituto opera bajo un modelo de gestión que prioriza la mejora continua, la inclusión, y el compromiso social. Su misión y visión reflejan el deseo de formar profesionales competentes, éticos y capaces de generar un impacto positivo en la sociedad.

1.3 Análisis del Problema

La deserción estudiantil en centros de estudio superiores en Perú emerge como una problemática que requiere una consideración profunda por su impacto en la calidad educativa y el desarrollo nacional. Esta problemática no solo representa un desperdicio de recursos financieros y humanos para las instituciones educativas, sino que también limita las oportunidades de crecimiento y movilidad social para los estudiantes afectados (Camejo et al., 2019).

Investigaciones actuales indican que, en el contexto peruano, el abandono de estudios está mayormente relacionado con aspectos socioeconómicos. Se ha observado una conexión notable entre los ingresos familiares y las tasas de abandono escolar, lo que sugiere que los factores económicos representan obstáculos importantes para la continuidad en la educación. (Cueto et al., 2020).

Con la evolución tecnológica, particularmente en el ámbito de aprendizaje automático (machine learning), surge herramientas que abordan y atenúan esta problemática. Mediante técnicas avanzadas de análisis de datos, el ML tiene el potencial de descifrar patrones ocultos y anticipar trayectorias de deserción, permitiendo a las instituciones educativas diseñar intervenciones más precisas y personalizadas (Aulck et al., 2017) .

Sin embargo, es crítico enfatizar que la aplicación efectiva del ML en el contexto educativo peruano requiere de una adaptación y validación meticulosa. Existe una imperiosa necesidad de conducir investigaciones rigurosas que permitan adaptar y optimizar modelos de ML para predecir y mitigar la deserción en el particular contexto socioeconómico y educativo del Perú(Dávila Morán et al., 2022).

1.4 Objetivos

1.4.1 General

Implementar un modelo de aprendizaje automático para disminuir la tasa de deserción de estudiantes antiguos en un centro de estudio superior

1.4.2 Específicos


- Analizar los modelos de aprendizaje automático que permitan disminuir la tasa de deserción de estudiantes
- Diseñar el modelo de aprendizaje automático que permitan disminuir la tasa de deserción de estudiantes
- Validar el modelo de aprendizaje automático utilizando un escenario y métricas de validación
- Elaborar el plan de continuidad que garantice, a lo largo del tiempo, la sostenibilidad y estabilidad del modelo propuesto.

1.5 Indicadores de Éxito

- Acta de conformidad del análisis del modelo de aprendizaje automático
- Acta de conformidad del diseño del modelo de aprendizaje automático
- Acta de conformidad de la validación del modelo de aprendizaje automático
- Acta de conformidad del plan de continuidad

1.6 Planificación del Proyecto

Figura 1
Diagrama de Gantt de planificación del proyecto



2 CAPÍTULO 2: MARCO TEÓRICO

2.1 Marco Conceptual

- Alumno antiguo
Se refiere a un estudiante que ha completado satisfactoriamente un ciclo de estudios en un instituto o centro educativo y está matriculado activamente en dicho programa.
- Deserción estudiantil

La situación de deserción estudiantil se caracteriza por la ausencia frecuente del estudiante en las clases, llegando eventualmente a abandonar el sistema educativo (Hernández et al., 2022). Por ende, es una dificultad que afecta a las instituciones de educación superior en sus compromisos sociales, así como en sus esfuerzos y planes económicos y de sostenibilidad (Acosta & Puentes, 2019).

- Aprendizaje automático

Es una rama de la inteligencia artificial (IA) que posibilita a las computadoras aprender de la información a la que tienen acceso y mejorar sus capacidades a medida que adquieren experiencia, prescindiendo de una programación directa. Este ámbito se concentra en el desarrollo de sistemas informáticos capaces de interpretar y aprender de los datos con los que interactúan, con el propósito de reconocer patrones y relaciones en diversos conjuntos de datos (SAP, 2023) .

- Análisis predictivo

El análisis predictivo es una técnica que utiliza una variedad de métodos estadísticos, de modelización, aprendizaje automático y minería de datos para analizar datos actuales e históricos y hacer predicciones sobre el futuro o eventos desconocidos (Sajid et al., 2021).

- Algoritmos de regresión

Los algoritmos de regresión son un conjunto de técnicas estadísticas que se utilizan para predecir valores de salida basándose en las características de entrada de los datos. Estos algoritmos construyen un modelo sobre las características de los datos de entrenamiento y utilizan el modelo para predecir el valor de nuevos datos (Camejo et al., 2019) .

- Algoritmos de clasificación

Los algoritmos de clasificación se refieren a un conjunto de métodos empleados en el campo del aprendizaje automático para categorizar objetos en diferentes clases. Como objetivo principal las técnicas de clasificación automática son utilizadas para desarrollar un modelo que pueda identificar la categoría a la que pertenece un objeto de manera automática (Cormen et al., 2009).

- Algoritmos de boosting

Los algoritmos de "boosting" o potenciación, son técnicas de aprendizaje automático que se enfocan en construir una serie de modelos predictivos, generalmente débiles, que trabajan en conjunto para crear un modelo más robusto y preciso. Este proceso se realiza de manera secuencial, donde cada modelo subsiguiente trata de corregir los errores cometidos por los modelos anteriores, asignando mayor peso a las observaciones que fueron mal clasificadas en las etapas anteriores. El objetivo central de los algoritmos de boosting es reducir el sesgo y la varianza, mejorando así la capacidad predictiva del modelo final. Entre las técnicas de boosting más conocidas se encuentran AdaBoost, Gradient Boosting Machine (GBM) y XGBoost (Hastie et al., 2009).

- Algoritmo LightGBM

LightGBM, que significa "Light Gradient Boosting Machine", es un marco de aprendizaje automático de código abierto que ofrece una implementación eficiente y escalable de algoritmos de boosting, en particular el gradient boosting, que está diseñado para acelerar el proceso de entrenamiento de los modelos sin comprometer su precisión. Aprovecha una estrategia de crecimiento de árbol basada en hojas, en contraste con la estrategia convencional basada en nivel utilizada por otros algoritmos de boosting, permitiendo así un aprendizaje más rápido y una mayor eficiencia en conjuntos de datos grandes. Además, LightGBM soporta el aprendizaje distribuido y puede manejar grandes volúmenes de datos con una menor utilización de memoria (Microsoft, 2023).

- Algoritmo RUSBoost

Algoritmo diseñado para manejar problemas de desequilibrio de clases en datos con etiquetas de clase discretas, donde combina RUS (submuestreo aleatorio) y el procedimiento estándar de boosting, AdaBoost, para modelar mejor la clase minoritaria mediante la eliminación de muestras de la clase mayoritaria (Seiffert et al., 2010).

- Algoritmo GausNB

Gaussian Naive Bayes es una variante del algoritmo de clasificación Naive Bayes diseñado específicamente para manejar características continuas. A diferencia de otras versiones del Naive Bayes que tratan los datos de entrada como categóricos, el Gaussian Naive Bayes asume que los datos de cada característica siguen una distribución normal o gaussiana. Este supuesto permite al algoritmo calcular la probabilidad de una muestra dada, basándose en la media y la desviación estándar de las características en el conjunto de entrenamiento (Vahid Mirjalili, 2019).

- Business Intelligence

Se refiere a un conjunto de procesos, tecnologías y herramientas que permiten a las organizaciones recopilar, almacenar, analizar y presentar datos empresariales con el fin de tomar decisiones informadas y estratégicas. Implica la transformación de datos en información útil y significativa, lo que facilita a los líderes empresariales la identificación de patrones, tendencias y oportunidades, así como la mejora de la eficiencia operativa y la toma de decisiones basadas en evidencia (Kimball & Ross, 2013) .

2.2 Estándares, frameworks y buenas prácticas

- Scrum

Marco de trabajo ágil ampliamente utilizado en la gestión de proyectos de desarrollo de software. Se apoya en principios de transparencia, revisión y adaptación para impulsar la colaboración y la entrega continua de valor al cliente (Schwaber, 2004).

- Product Owner

El Product Owner desempeña un papel crucial en Scrum al representar las necesidades y prioridades de los stakeholders ante el equipo de desarrollo. Este rol trabaja en estrecha

colaboración con los interesados para identificar y priorizar las funcionalidades y características clave del producto. La responsabilidad del Product Owner incluye mantener el Product Backlog, una lista priorizada de elementos de trabajo, y asegurarse de que el equipo se enfoque en la entrega de valor a lo largo del proyecto (Cohn, 2004) .

- Product Backlog

El Product Backlog es una herramienta fundamental en Scrum que sirve como fuente principal de requerimientos para el equipo de desarrollo. Esta lista dinámica y priorizada contiene elementos que describen funcionalidades, mejoras y correcciones deseadas para el producto. La gestión y priorización del Product Backlog recae en el Product Owner, quien asegura que los elementos estén claramente definidos y se prioricen en función de su valor para el negocio (Schwaber, 2004) .

- Daily Scrum

Conocida como reunión diaria, es una práctica esencial en Scrum para mantener al equipo de desarrollo sincronizado y enfocado en los objetivos del Sprint. En esta reunión diaria, cada miembro del equipo comparte brevemente lo que trabajo de manera global ,lo que planea hacer en el día actual y si enfrenta algún obstáculo en su trabajo. Esta colaboración en tiempo real es fundamental para identificar y resolver problemas rápidamente (Sutherland, 2014) .

- Sprint Planning

La Sprint Planning es un evento clave en Scrum que inicia cada Sprint. El equipo de desarrollo trabaja junto con el Product Owner para seleccionar y comprometerse con los elementos del Product Backlog que se abordarán en el próximo Sprint. Se definen las tareas específicas necesarias para completar estos elementos, lo que permite al equipo tener una comprensión compartida de lo que se espera lograr en el Sprint (Cohn, 2007) .

2.3 Bases Legales y Marco Normativo

- Ley de Protección de Datos Personales

La Ley N° 29733 de Protección de Datos Personales de Perú, creada en 2011, regula la manera en que las entidades gubernamentales y privadas manejan los datos personales de los ciudadanos peruanos, promoviendo la transparencia y el consentimiento del titular durante su recopilación y uso. A través de esta normativa, se busca garantizar el respeto a los derechos fundamentales relacionados con la privacidad de los datos, incentivando la autorregulación de las entidades poseedoras de bases de datos. Además, otorga a los individuos el derecho de supervisar y modificar su información personal en las bases de datos, estableciendo fuertes sanciones para los infractores (Congreso de la República del Perú, 2003).

- Ley General de Educación

La Ley General de Educación, Ley N° 28044, constituye el marco legal que rige el sector educativo en Perú, estableciendo los lineamientos para asegurar la educación. Esta normativa establece los principios, garantías y lineamientos que orientan la educación peruana, promoviendo una formación que respeta la diversidad cultural, fomenta una ciudadanía democrática y estimula el desarrollo sostenible. Adicionalmente, la ley dispone la organización, gestión y supervisión de los servicios educativos, abogando por una formación inclusiva, pertinente y equitativa en todo el territorio nacional (Congreso de la República del Perú, 2011) .

3 CAPÍTULO 3: DESARROLLO DEL PROYECTO

3.1 Diseño de la Solución

3.1.1 Análisis de tecnología para el proyecto

En la fase inicial del proyecto, se llevó a cabo análisis comparativos (Benchmarking) de algoritmos que ayuden para la predicción deserción estudiantil y los lenguajes de programación orientados a aprendizaje automático. A continuación, se detallan ambos análisis.

Tabla 1

Puntuación utilizada para los benchmarking

Puntuación	Descripción
5	Totalmente de acuerdo
4	De acuerdo
3	Ni de acuerdo ni en desacuerdo
2	En desacuerdo
1	Totalmente en desacuerdo

3.1.1.1 Benchmarking de algoritmos de aprendizaje automático

Tabla 2

Descripción de los criterios evaluados para el benchmarking de algoritmos de aprendizaje automático.

Nº	Criterio	Descripción
1	Exactitud	Capacidad del algoritmo para realizar predicciones correctas.
2	Velocidad de Entrenamiento	Tiempo que tarda el algoritmo en entrenarse con un conjunto de datos específico.
3	Facilidad de Implementación	Facilidad con la que se puede implementar y utilizar el algoritmo.
4	Escalabilidad	Habilidad del algoritmo para mantener su desempeño con un gran volumen de datos.
5	Versatilidad	Capacidad del algoritmo para adaptarse a diferentes tipos de problemas y conjuntos de datos.

Tabla 3*Tabla de priorización de criterios para el benchmarking*

	Criterios	A	B	C	D	E	Total	Impacto
A	Exactitud	X	5	4	4	4	17	21%
B	Velocidad de Entrenamiento	3	X	4	3	4	14	18%
C	Facilidad de Implementación	4	4	X	4	4	16	20%
D	Escalabilidad	4	5	4	X	4	17	21%
E	Versatilidad	4	4	4	4	X	16	20%
Total							80	100%

Tabla 4*Benchmarking de algoritmos de machine learning*

Criterio	Impacto	RUSBost		GausNB		Percept	LightGBM		
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Exactitud	21%	4	0,84	3	0,63	3	0,63	5	1,05
Velocidad de Entrenamiento	18%	3	0,54	4	0,72	2	0,36	4	0,72
Facilidad de Implementación	20%	3	0,60	3	0,60	4	0,80	4	0,80
Escalabilidad	21%	4	0,84	2	0,42	2	0,42	5	1,05
Versatilidad	20%	3	0,60	3	0,60	4	0,80	4	0,80
Total	100%	17	3,42	15	2,97	15	3,01	22	4,42

En el benchmarking desarrollado, se evaluaron cuatro populares algoritmos de aprendizaje automático: RUSBost, GausNB, Percept y LightGBM, basándose en criterios esenciales como la exactitud, la velocidad de entrenamiento, la facilidad de implementación, la escalabilidad y la versatilidad. La evaluación de estos criterios es vital para determinar la eficiencia y la efectividad de un algoritmo en diversas circunstancias y configuraciones de datos (Provost & Fawcett, 2013) .

En un estudio de benchmarking que evaluó cuatro algoritmos de aprendizaje automático, se destacó el algoritmo LightGBM por su alto rendimiento en exactitud y escalabilidad (Ke et al., 2017) . Su enfoque avanzado de división de hojas contribuye a su alta precisión al aprender de áreas críticas de los datos. Aunque su velocidad de entrenamiento y facilidad de implementación son comparables a otros algoritmos como GausNB, su capacidad para escalar eficientemente en grandes conjuntos de datos lo posiciona favorablemente, a pesar de requerir un conocimiento técnico avanzado para su implementación (Zheng & Casari, 2018). Por otro lado, mientras RUSBoost, GausNB y Percept tienen sus fortalezas en contextos específicos, LightGBM destaca como una opción potencialmente superior para tareas que requieran alta exactitud y escalabilidad, especialmente en situaciones con grandes volúmenes de datos, combinando velocidad, precisión y versatilidad.

3.1.1.2 Benchmarking de lenguajes de programación orientados a aprendizaje automático

Tabla 5

Descripción de los criterios evaluados para el benchmarking de lenguajes de programación orientados a aprendizaje automático

Nº	Criterio	Descripción
1	Facilidad de uso	Evalúa la simplicidad y la intuición de la sintaxis del lenguaje.
2	Comunidad y Soporte	Se refiere a la existencia de una comunidad activa y soporte disponible para los desarrolladores.
3	Bibliotecas y Herramientas	Analiza la disponibilidad y calidad de las bibliotecas y herramientas específicas para aprendizaje automático.
4	Eficiencia	Evalúa la capacidad del lenguaje para manejar grandes volúmenes de datos con rapidez y eficiencia.

Tabla 6

Tabla de priorización de criterios para el benchmarking de lenguajes de programación orientados a aprendizaje automático

	Criterios	A	B	C	D	Total	Impacto
A	Facilidad de uso	X	4	3	3	10	26%
B	Comunidad y Soporte	3	X	4	3	10	26%
C	Bibliotecas y Herramientas	3	3	X	4	10	25%
D	Eficiencia	3	3	3	X	19	23%
Total						39	100%

Tabla 7

Benchmarking de lenguajes de programación orientados a aprendizaje automático

		Python		R		Julia	
Criterio	Impacto	Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Facilidad de uso	26%	5	1,30	4	1,04	5	1,30
Comunidad y Soporte	26%	5	1,30	5	1,30	4	1,04
Bibliotecas y Herramientas	25%	5	1,25	5	1,25	5	1,25
Eficiencia	23%	4	0,92	4	0,92	5	1,15
Total	100%	19	4,77	18	4,51	19	4,74

En la evaluación de lenguajes para el aprendizaje automático, Python destaca por su facilidad de uso respaldada por una sintaxis clara, un amplio conjunto de bibliotecas como Scikit-learn, TensorFlow y PyTorch, y una comunidad global sólida que lo mantiene en la vanguardia (Chollet, 2017; Vanderplas, 2017) . Por otro lado, R ofrece herramientas especializadas en estadística, aunque puede ser limitado en eficiencia al manejar conjuntos de datos grandes, un área donde Julia parece sobresalir. Julia se destaca por su

eficiencia computacional y su capacidad para realizar cálculos complejos con mayor eficacia, ganando terreno en proyectos de alto procesamiento computacional (Bezanson et al., 2017; Wickham & Grolemund, 2017). Aunque aún en desarrollo, el rápido crecimiento de su comunidad y sus bibliotecas específicas indican un prometedor futuro en el campo del aprendizaje automático.

3.1.1.3 Benchmarking de plataformas de Business Intelligence

Tabla 8

Descripción de los criterios evaluados para el benchmarking de plataformas de Business Intelligence

Nº	Criterio	Descripción
1	Facilidad de uso	Capacidad de la plataforma para ser utilizada sin requerir habilidades técnicas avanzadas.
2	Integración de datos	Habilidad de la plataforma para integrar y manejar datos de diversas fuentes.
3	Visualización de datos	Calidad y variedad de las visualizaciones que la plataforma puede generar.
4	Colaboración	Capacidad de la plataforma para permitir la colaboración entre usuarios.
5	Escalabilidad	Habilidad de la plataforma para mantener su desempeño con un gran volumen de datos.

Tabla 9

Tabla de priorización de criterios para el benchmarking de plataformas de Business Intelligence

	Criterios	A	B	C	D	E	Total	Impacto
A	Facilidad de uso	X	4	3	5	4	16	22%
B	Integración de datos	3	X	4	4	5	16	22%
C	Visualización de datos	4	3	X	6	5	18	25%
D	Colaboración	2	3	3	X	4	12	17%
E	Escalabilidad	3	2	2	3	X	10	14%
Total							72	100%

Tabla 10
Benchmarking de plataformas de Business Intelligence

		Power BI		Tableau		Looker		QlikView	
Criterio	Impa cto	Punt aje	Prome dio	Punt aje	Prome dio	Punt aje	Prome dio	Punt aje	Prome dio
Facilidad de uso	22%	4	0,88	5	1,1	5	1,1	3	0,66
Integración de datos	22%	5	1,1	4	0,88	4	0,88	3	0,66
Visualización de datos	25%	5	1,25	4	1	3	0,75	4	1
Colaboración	17%	3	0,51	4	0,68	3	0,51	3	0,51
Escalabilidad	14%	5	0,7	3	0,42	4	0,56	3	0,42
Total	100%	22	4,44	20	4,08	19	3,8	16	3,25

En una evaluación de benchmarking de plataformas de Business Intelligence (BI) como Power BI, Tableau, Looker y QlikView, se destacan las fortalezas de cada una. Power BI sobresale por su versatilidad, facilidad de uso y capacidad para la gestión e integración de datos provenientes de diversas fuentes, junto con una amplia gama de herramientas de visualización (Srivastava et al., 2022). Tableau, a pesar de posibles limitaciones en escalabilidad, ofrece una interfaz intuitiva y un sólido respaldo comunitario para una fácil adopción y colaboración (Batt et al., 2020; Bhombe et al., 2019). Looker muestra efectividad en la facilidad de uso y la integración de datos, pero con limitaciones en la visualización, aunque destaca en escalabilidad para proyectos con alto procesamiento

computacional (Perez et al., 2023; Yanto et al., 2023). Por otro lado, QlikView tiene un rendimiento satisfactorio en general, aunque no alcanza los estándares de las otras plataformas en facilidad de uso e integración de datos, siendo similar en fomentar la colaboración (Lousa et al., 2019; Yousif & Zakaria, 2022) .

3.1.1.4 Benchmarking de bases de datos para aprendizaje profundo

Tabla 11

Descripción de los criterios evaluados para el benchmarking de bases de datos para aprendizaje profundo

Nº	Criterio	Descripción
1	Facilidad de uso	Capacidad de la base de datos para ser utilizada sin requerir habilidades técnicas avanzadas.
2	Integración de datos	Habilidad de la base de datos para integrar y manejar datos de diversas fuentes.
3	Velocidad de procesamiento	Tiempo que tarda la base de datos en procesar un conjunto de datos específico.
4	Escalabilidad	Habilidad de la base de datos para mantener su desempeño con un gran volumen de datos.
5	Soporte y comunidad	El soporte disponible y el tamaño y actividad de la comunidad.

Tabla 12

Tabla de priorización de criterios para el benchmarking de bases de datos para aprendizaje profundo

	Criterios	A	B	C	D	E	Total	Impacto
A	Facilidad de uso	X	4	3	5	4	16	23%
B	Integración de datos	3	X	4	4	5	16	23%
C	Velocidad de procesamiento	4	3	X	4	5	16	23%
D	Escalabilidad	2	3	3	X	4	12	17%
E	Soporte y comunidad	3	2	2	3	X	10	14%
Total							70	100%

Tabla 13*Benchmarking de bases de datos para aprendizaje profundo*

Criterio	Imp acto	Oracle		Apache Cassandra		PostgreSQL		Couchbase	
		Punt aje	Prom edio	Punt aje	Prom edio	Punt aje	Prom edio	Punt aje	Prom edio
Facilidad de uso	23%	4	0,91	4	0,91	4	0,91	3	0,69
Integración de datos	23%	5	1,14	3	0,69	3	0,69	3	0,69
Velocidad de procesamiento	23%	5	1,14	4	0,91	3	0,69	3	0,69
Escalabilidad	17%	3	0,69	4	0,91	4	0,91	4	0,91
Soporte y comunidad	14%	5	1,14	3	0,69	3	0,69	2	0,46
Total	100 %	22	5,03	18	4,11	17	3,89	15	3,43

En el proceso de benchmarking, se llevó a cabo una evaluación exhaustiva de cuatro destacadas bases de datos utilizadas en el ámbito del aprendizaje profundo: Oracle, Apache Cassandra, PostgreSQL y Couchbase (Tabla 16). El propósito primordial de este análisis consistió en ofrecer una evaluación rigurosa con el fin de respaldar la selección informada de la base de datos más adecuada para entornos de aprendizaje profundo y análisis de datos.

Según el benchmarking realizado, Oracle recibió una alta puntuación en facilidad de uso. Además, se destacó su capacidad de integración de datos y velocidad de procesamiento (Filip & Cegan, 2020). En contraste, Apache Cassandra demostró una velocidad de procesamiento y escalabilidad superiores (Shirinbab et al., 2020). No obstante, se evidenciaron limitaciones en cuanto a facilidad de uso y soporte de la comunidad (Chaudhari & Mulay, 2019). PostgreSQL, a pesar de similitudes con Oracle en facilidad de uso e integración de datos, presentó una velocidad de procesamiento relativamente menor (Makris et al., 2021). También se señalaron aspectos relacionados con la escalabilidad y el soporte comunitario que requieren consideración al seleccionar esta base de datos para aplicaciones de aprendizaje profundo (Ortiz et al., 2019). Finalmente, Couchbase exhibió puntajes favorables en escalabilidad, pero enfrentó desafíos en la velocidad de procesamiento y el soporte comunitario (Ostrovsky et al., 2015).

3.1.2 Análisis del proceso de negocio AS-IS y TO-BE

3.1.2.1 Proceso de priorización de estudiantes

El proceso se centra en la priorización de contacto alumnos antiguos, desde la compilación de los datos de estudiantes actuales hasta la evaluación de su relevancia. En el Anexo 1 se representa el proceso actual de manera general, mientras que en el Anexo 2 se propone la implementación de tecnología de aprendizaje automático.


Para mayor detalle véase:

- Anexo 1: Proceso de priorización de alumnos antiguos (As - Is)
- Anexo 2: Proceso de priorización de alumnos antiguos (To - Be)

3.1.3.1 ARQUITECTURA LÓGICA

En la Figura 2 se muestra la arquitectura lógica del datawarehouse en la cual se tiene las distintas fuentes de datos y la herramienta que se utiliza para cargar los datos al datawarehouse. El datawarehouse se compone por 4 capas, capa staging (réplicas de datos de las fuentes de datos), capa mapping (tablas intermedias), capa analítica (tablas con lógicas de negocio y analítica) y la capa predictiva (tablas de entrenamiento y resultados del modelo). Por último, la capa de Business Intelligence que es la capa donde se publica los reportes en Power bi o archivos que se exportan automáticamente hacia Google Drive.

Figura 2
Arquitectura lógica de datawarehouse



3.1.3.3 Visualización de la solución

En la Figura 3 se observa el reporte con el porcentaje de predicción por estudiante y su categoría de variable donde 1 es la más importante en la predicción y 12 es la menos importante. Así mismo, en la Figura 4 se observa un tablero gerencial donde semana académica cómo va la deserción estudiantil acumulada.

Figura 3
Dashboard de la solución del modelo predictivo

DESCRIPCION_PROGRAMA		PREDICCION	RIESGO		FLG_DESERCION				
Todas		Desertor	Todas		0				
PREDICCION	RIESGO	PROBABILIDAD	ANIO_FIN_COLEGIO_RANK	CANAL_VENTA_RANK	COBRIS_RANK	CONTACTABILIDAD_VENTA_RANK	DIAGNOSTICO_RANK	DURACION_CARRERA_RANK	EDAD_RANK
Desertor	ALTO	0.76	5.00	11.00	9.00	7.00	5.00	10.00	4
Desertor	ALTO	0.78	6.00	9.00	8.00	3.00	1.00	4.00	2
Desertor	MEDIO	0.64	6.00	11.00	7.00	3.00	2.00	5.00	1
Desertor	ALTO	0.78	9.00	2.00	6.00	10.00	1.00	6.00	3
Desertor	MEDIO	0.66	8.00	11.00	9.00	7.00	2.00	5.00	1
Desertor	ALTO	0.87	5.00	7.00	4.00	9.00	11.00	6.00	1
Desertor	ALTO	0.79	4.00	6.00	9.00	11.00	8.00	10.00	2
Desertor	MEDIO	0.64	5.00	2.00	7.00	3.00	11.00	6.00	1
Desertor	MUY ALTO	0.97	10.00	3.00	6.00	4.00	2.00	8.00	1
Desertor	MEDIO	0.71	6.00	9.00	5.00	11.00	10.00	7.00	2
Desertor	ALTO	0.85	2.00	6.00	5.00	9.00	11.00	7.00	1
Desertor	ALTO	0.89	2.00	7.00	4.00	8.00	11.00	8.00	10
Desertor	MEDIO	0.65	8.00	3.00	10.00	11.00	9.00	5.00	4
Desertor	MUY ALTO	0.97	10.00	4.00	7.00	5.00	2.00	8.00	1
Desertor	ALTO	0.82	6.00	4.00	5.00	10.00	11.00	9.00	1
Desertor	ALTO	0.87	11.00	5.00	8.00	7.00	10.00	9.00	1
Desertor	MUY ALTO	0.94	8.00	7.00	3.00	11.00	6.00	5.00	1
Desertor	MEDIO	0.69	3.00	2.00	7.00	5.00	10.00	8.00	1
Desertor	MEDIO	0.60	11.00	6.00	5.00	7.00	1.00	4.00	2
Desertor	ALTO	0.76	4.00	3.00	7.00	9.00	10.00	5.00	6
Desertor	MEDIO	0.67	6.00	3.00	11.00	10.00	9.00	5.00	2
Total									

Figura 4
Dashboard Gerencial impacto del modelo predictivo



3.2 Desarrollo de la Solución

Para el desarrollo de la solución se elaboró una tabla en Oracle con los siguientes campos. Asimismo, se detalla el tipo de variable, la categoría de la variable y su definición en la Tabla 14.

Tabla 14
Variables más importantes del modelo

VARIABLE	TIPO_D ATO	TIPO_VARI ABLE	CATEGORIA_VARIABL ES	DEFINIC ION
----------	---------------	-------------------	-------------------------	----------------

CODIGO_ESTUDIANTE	INT	NUMERICA	SIN CATEGORIA	CODIGO DEL ESTUDIANTE PARA AREA ACADEMICA
CICLO_ESTUDIANTE	VARCHAR	CATEGORICA	INFORMACION_ESTUDIAN TIL_RANK	CICLO DEL ESTUDIANTE
CARRERA	VARCHAR	CATEGORICA	INFORMACION_ESTUDIAN TIL_RANK	CARRERA DEL ESTUDIANTE
RATIO_ASISTENCIA_ACUMULADO	DOUBLE	NUMERICA	ASISTENCIA_RANK	PORCENTAJE DE ASISTENCIA ACUMULADA DEL ESTUDIANTE
TURNO_ESTUDIO	VARCHAR	CATEGORICA	TURNO_ESTUDIO_RANK	TURNOS DE ESTUDIO DEL ESTUDIANTE

Para mayor detalle de las variables que se emplearon en el modelo véase en:

- Anexo 3: Variables del modelo predictivo

Por motivos de confidencialidad de información se mostrarán solo tres variables que entraron en la evaluación de análisis de datos y en el análisis WOE .

Figura 5

Variable Ciclo de estudiante (Evaluación de análisis de datos y Análisis WOE)




Figura 6

Variable Turno Estudio (Evaluación de análisis de datos y Análisis WOE)




Figura 7

Variable Ratio Asistencia Acumulado (Evaluación de análisis de datos y Análisis WOE)




Tabla 15*Comparación de algoritmo del modelo*

Métrica	RUSBost	GausNB	Percept	LightGBM
F1 mean	84.85	83.69	79.29	85.81
F1 weighted mean mean	79.87	78.18	71.40	80.27
F2 weighted mean mean	79.70	78.03	71.43	80.32
G-mean weighted mean mean	76.65	75.38	66.51	77.59
ROC AUC mean	76.74	75.42	66.71	77.61
Precision mean	85.26	85.24	79.26	86.83
Recall mean	82.96	82.19	79.49	86.37

Nota. Elaboración propia

F1 mean (Promedio F1): Esta métrica es una media armónica entre la precisión y el recall, donde valores cercanos a 100 indican un excelente balance.

- LightGBM tiene el mejor rendimiento, seguido de cerca por RUSBost, luego GausNB y finalmente Percept. LightGBM parece balancear mejor la precisión y recall en general.

F1 weighted mean (Promedio ponderado F1): Es una versión del F1 que tiene en cuenta el desequilibrio entre clases.

- Nuevamente, LightGBM es el líder, seguido de RUSBost, GausNB y Percept. Esto indica que LightGBM maneja mejor el desequilibrio de clases.

F2 weighted mean (Promedio ponderado F2): El puntaje F2 pondera el recall dos veces más que la precisión y es útil cuando el recall es más importante que la precisión.

- LightGBM lidera ligeramente por encima de RUSBost, con GausNB en tercer lugar y Percept al final. Esto sugiere que tanto LightGBM como RUSBost priorizan el recall de manera efectiva.

G-mean weighted mean (Media geométrica ponderada): Es la raíz cuadrada del producto de la sensibilidad (recall) y la especificidad, es útil para evaluar el rendimiento en conjuntos de datos desequilibrados.

- LightGBM es el líder, seguido por RUSBoost, GausNB y finalmente Percept. Esto indica que RUSBoost tiene un buen compromiso entre sensibilidad y especificidad, especialmente en conjuntos de datos desequilibrados.

ROC AUC mean (Promedio del área bajo la curva ROC): Refleja la habilidad del modelo para distinguir entre las categorías positivas y negativas, valores cercanos a 1 son ideales.

- LightGBM tiene la mejor capacidad discriminativa, seguido de cerca por RUSBoost, luego GausNB y finalmente Percept.

Precision mean (Promedio de precisión): Representa la proporción de identificaciones positivas que fueron realmente correctas.

- LightGBM tiene la mayor precisión, seguido por RUSBoost, GausNB, y finalmente Percept.

Recall mean (Promedio de recall o sensibilidad): Representa la proporción de positivos reales que fueron identificados correctamente.

- LightGBM destaca con el mayor recall, seguido por RUSBoost, GausNB y finalmente Percept.

3.4 Interpretación de los Resultados

LightGBM y RUSBoost son los algoritmos de mejor rendimiento en la mayoría de las métricas, con LightGBM liderando en la mayoría de ellas. GausNB es el tercer mejor algoritmo, mientras que Percept tiende a tener el rendimiento más bajo en todas las

métricas. Basado en estas métricas y dependiendo de la importancia de cada métrica para el problema planteado, podría considerarse priorizar el uso de LightGBM para el proyecto.

3.5 Plan de continuidad

A continuación, se detalla cada fase del ciclo Deming aplicado a nuestro modelo, describiendo las actividades, los procedimientos y las responsabilidades asociadas para asegurar la correcta implementación, monitoreo, evaluación y mejora.

3.5.1 Planificar (Plan):

Objetivo: Establecer objetivos claros para el sostenimiento y mejora del modelo.

- Revisión del propósito: Recordar y reevaluar el objetivo del proyecto. ¿El objetivo sigue siendo el mismo o ha evolucionado?
- Métricas de referencia: Establecer métricas de rendimiento actual del modelo para comparar en futuras evaluaciones.
- Identificar posibles desafíos: ¿Hay factores externos que podrían afectar el desempeño del modelo en el futuro? Por ejemplo, cambios en la demografía estudiantil, evolución del sistema educativo, etc.

3.5.2 Hacer (Do):

Objetivo: Ejecutar acciones proactivas y preventivas.

- Backup: Asegurar copias de seguridad del modelo, datos de entrenamiento y cualquier recurso asociado.
- Actualizaciones periódicas: Establecer un cronograma para revisar y actualizar el modelo. Esto puede ser cada semestre o año, dependiendo de las necesidades.
- Formación continua: Capacitar al personal para que esté al tanto de cómo funciona el modelo y cómo se puede mejorar.

3.5.3 Comprobar (Check):

Objetivo: Monitorizar y evaluar el rendimiento del modelo regularmente.

- Monitoreo de información: Establecer herramientas que permitan observar el rendimiento del modelo de manera periódica definida por el negocio.
- Evaluaciones periódicas: Comparar el rendimiento actual con las métricas de referencia establecidas.
- Recopilación de feedback: Obtener retroalimentación de los usuarios y stakeholders para identificar posibles áreas de mejora.

3.5.4 Actuar (Act):

Objetivo: Hacer ajustes basados en las evaluaciones y el feedback.

- Reentrenamiento: Si se detectan cambios significativos en los datos o en el rendimiento del modelo, considerar un reentrenamiento.
- Ajuste y optimización: Realizar ajustes basados en la retroalimentación y las métricas.
- Revisión de objetivos: Si el contexto ha cambiado considerablemente, revisar y ajustar los objetivos del modelo.
- Comunicación: Informar a los stakeholders sobre los cambios y mejoras realizadas.

4 CONCLUSIONES Y RECOMENDACIONES

4.1 Conclusiones

El proyecto abordó de manera integral priorizar el contacto con alumnos antiguos, utilizando análisis y selección de algoritmos, en particular, la elección de LightGBM por sus superiores métricas de rendimiento (mencionar otras técnicas de comparación de algoritmos). A lo largo del desarrollo, se mostró una cuidadosa atención al detalle, desde la definición y categorización de variables hasta la validación de los resultados. La inclusión de un plan de continuidad basado en el ciclo Deming refleja una visión a largo plazo, garantizando no solo la implementación del modelo, sino también su adaptabilidad y mejora continua en el futuro. Se realizó la comparación con el periodo 2022-1 cuyo su deserción de alumnos antiguos fue de 13.45% y la deserción de alumnos antiguos del periodo 2023-1 fue del 9.45%. Esto evidencia una disminución en la deserción gracias a la implementación del modelo.

4.2 Recomendaciones

- El entorno educativo y las causas subyacentes de la deserción pueden cambiar con el tiempo. Es vital que el modelo pueda adaptarse a estos cambios.
- Se recomienda considerar el análisis de componentes principales (PCA), ya que se enfocará en las variables más influyentes del modelo y acelera el tiempo de entrenamiento.
- Aplicar un modelo híbrido que combina técnicas no supervisadas (K-means) con técnicas supervisadas como es LightGBM. Esto permitirá mejorar la precisión de las predicciones al considerar que los datos pueden agruparse en subconjuntos con características similares y cada cluster se sometería a un modelo supervisado individual, lo que podría resultar en una mayor precisión al tener en cuenta las particularidades de cada grupo.

- Explorar estrategias de inteligencia artificial, como el aprendizaje por reforzamiento (RL) permitiendo que el modelo de aprendizaje automático se adapte dinámicamente a situaciones cambiantes y complejas en base a la experiencia acumulada.

5 REFERENCIAS

- Acosta, I. A., & Puentes, G. A. (2019). *Definición de un modelo predictivo para la deserción estudiantil en educación virtual y a distancia*. [Tesis de Maestría], Escuela Colombiana de ingeniería Julio Garavito. Repositorio institucional de la ECIG. <https://repositorio.escuelaing.edu.co/handle/001/1054>
- Alpaydin, E. (2020). *Introduction to Machine Learning (4a ed.)*. MIT Press
- Aulck, L., Velagapudi, N., Blumenstock, J., & West, J. (2017). *Predicting Student Dropout in Higher Education*. <https://browse.arxiv.org/pdf/1606.06364.pdf>
- Batt, S., Grealis, T., Harmon, O., & Tomolonis, P. (2020). Learning Tableau: A data visualization tool. *Journal of Economic Education*, 51(3–4), 317–328. <https://doi.org/10.1080/00220485.2020.1804503>
- Bezanson, J., Edelman, A., Karpinski, S., & Shah, V. B. (2017). Julia: A Fresh Approach to Numerical Computing. *SIAM Review*, 59(1), 65–98. <https://doi.org/10.1137/141000671>
- Bhombe, A., Walukar, K., Thakare, Y., & Kamble, S. (2019). *Comparative Analysis of two BI tools: Micro Strategy and Tableau*. <https://ssrn.com/abstract=3462539>
- Camejo Corona, J., Gonzalez, H., & Morrel, C. (2019). Los principales algoritmos para regresión con salidas múltiples. Una revisión para Big Data. *Los Principales Algoritmos Para Regresión Con Salidas Múltiples. Una Revisión Para Big Data*, 13(4), 118–150. http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S2227-18992019000400118&lng=es&tlng=es
- Camejo, J., Gonzalez, H., & Morrel, C. (2019). Los principales algoritmos para regresión con salidas múltiples. Una revisión para Big Data. Los Principales Algoritmos Para Regresión Con Salidas Múltiples. Una Revisión Para Big Data, *Revista Cubana de ciencias informáticas* 13(4), 118–150. http://scielo.sld.cu/scielo.php?script=sci_arttext&pid=S2227-18992019000400118&lng=es&tlng=es
- Chaudhari, A. A., & Mulay, P. (2019). SCSi: Real-Time Data Analysis with Cassandra and Spark. In *Studies in Big Data* (Vol. 43). https://doi.org/10.1007/978-981-13-0550-4_11

- Chollet, F. (2017). *Deep Learning with Python*. Anaya Multimedia.
- Cohn, M. (2004). User Stories Applied for Agile Software Development. Addison-Wesley. <https://www.mountangoatsoftware.com/uploads/articles/User-Stories-Applied-Mike-Cohn.pdf>
- Cohn, M. (2007). *Agile Estimating and Planning*. https://eva.fing.edu.uy/pluginfile.php/248476/mod_label/intro/%282005%29%20Cohn%20-%20Agile%20Estimating%20and%20Planning.pdf?time=1558526842604
- Congreso de la República del Perú. (2003). *Ley N° 29733, Ley General de Educación*. <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/243470-29733>
- Congreso de la República del Perú. (2011). *Ley N° 28044, Ley de Protección de Datos Personales*. <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/243470-29733>
- Cormen, T., Leiserson, C., Rivest, R., & Stein, C. (2009). *Introduction to Algorithms*. The MIT Press. https://pd.daffodilvarsity.edu.bd/course/material/book-430/pdf_content
- Cueto, S., Felipe, C., & León, J. (2020). *Predictores de la deserción escolar en el Perú*. 52. <https://www.grade.org.pe/wp-content/uploads/GRADEap52.pdf>
- Dávila Morán, R. C., Agüero Corzo, E. del C., Portillo Rios, H., & Quimbita Chiluisa, Q. C. (2022a). Deserción universitaria de los estudiantes de una universidad peruana. *Revista Universidad y Sociedad*, 421–427. <https://rus.ucf.edu.cu/index.php/rus/article/view/2722/2680>
- Dávila Morán, R. C., Agüero Corzo, E. del C., Portillo Rios, H., & Quimbita Chiluisa, Q. C. (2022b). Vista de Deserción universitaria de los estudiantes de una universidad peruana. *Revista Universidad y Sociedad*, 421–427. <https://rus.ucf.edu.cu/index.php/rus/article/view/2722/2680>
- Elías, M., Rivera, L., & Rodríguez Vásquez, J. M. (2022). El factor económico como principal causa de deserción estudiantil universitaria en Centroamérica. *Revista Entorno*, 1, 60–70. <https://doi.org/10.5377/entorno.v1i73.15668>
- Filip, P., & Cegan, L. (2020). Comparison of MySQL and MongoDB with focus on performance. *Proceedings - 2nd International Conference on Informatics*,

- Multimedia, Cyber, and Information System, ICIMCIS 2020.*
<https://doi.org/10.1109/ICIMCIS51567.2020.9354307>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
<https://www.deeplearningbook.org/>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). <https://link.springer.com/book/10.1007/978-0-387-84858-7>
- Hernández, D. R., L. Vázquez, O., & Leija, H. D. G. (2022). CAUSALES DE LA DESERCIÓN ESCOLAR EN MÉXICO, PERSPECTIVA DESDE UN ANÁLISIS DOCUMENTAL. *TECTZAPIC. Revista Académico-Científica*, 9–20.
<https://doi.org/10.51896/TECTZAPIC/SIEO5632>
- Hernández-Blanco, A., Herrera-Flores, B., Tomás, D., & Navarro-Colorado, B. (2019). *A Systematic Review of Deep Learning Approaches to Educational Data Mining*.
<https://doi.org/10.1155/2019/1306039>
- Jiménez, O., Jesús, A., & Wong, L. (2023). Model for the Prediction of Dropout in Higher Education in Peru applying Machine Learning Algorithms: Random Forest, Decision Tree, Neural Network and Support Vector Machine. *2023 33rd Conference of Open Innovations Association (FRUCT)*, 116–124.
<https://doi.org/10.23919/FRUCT58615.2023.10143068>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*.
<https://github.com/Microsoft/LightGBM>.
- Kimball, R., & Ross, M. (2013). *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling* (3rd ed.). Wiley.
https://www.academia.edu/9156395/The_Data_Warehouse_Toolkit_The_Complete_Guide_to_Dimensional_Modeling_2nd_Ed_2002_Wiley_Kim
- Lousa, A., Pedrosa, I., & Bernardino, J. (2019). Evaluation and Analysis of Business Intelligence Data Visualization Tools. *14th Iberian Conference on Information Systems and Technologies (CISTI)*.
<https://ieeexplore.ieee.org/abstract/document/8760677>

- Makris, A., Tserpes, K., Spiliopoulos, G., Zissis, D., & Anagnostopoulos, D. (2021). MongoDB Vs PostgreSQL: A comparative study on performance aspects. *GeoInformatica*, 25(2). <https://doi.org/10.1007/s10707-020-00407-w>
- Microsoft. (2023). *¿Qué es LightGBM?* <https://learn.microsoft.com/es-es/fabric/data-science/lightgbm-overview>
- Organización de las Naciones Unidas para la Educación la Ciencia y la Cultura. (2020). *Global education monitoring report, 2020: Inclusion and education: all means all*. Recuperado: 20 diciembre de 2023 ,de <https://unesdoc.unesco.org/ark:/48223/pf0000373718>
- Organización para la Cooperación y el Desarrollo Económico. (2019). *Panorama de la educación Indicadores de la OCDE 2019*. https://www.observatoriodelainfancia.es/ficherosoia/documentos/5860_d_panorama_educacion_OCDE_espana2019.pdf
- Ortiz, J., Balazinska, M., Gehrke, J., & Keerthi, S. S. (2019). *An Empirical Analysis of Deep Learning for Cardinality Estimation*. <http://arxiv.org/abs/1905.06425>
- Ostrovsky, D., Haji, M., & Rodenski, Y. (2015). Designing Document-Oriented Databases with Couchbase. In *Pro Couchbase Server*. https://doi.org/10.1007/978-1-4842-1185-4_2
- Pereira Santana, A. E., & Vidal Cortez, M. (2020). Deserción estudiantil en la educación superior: reflexiones sobre la gestión enfocada en la retención o la permanencia. *Revista Educación*, 519–533. <https://doi.org/10.15517/revedu.v45i1.40602>
- Perez, A., Vasilev, B., Agic, Z., Thrysøe, C., Hargitai, V., Dahlgaard, M., & Røssel, C. (2023). Accelerating and Scaling Data Products with Serverless. In *Lecture Notes on Data Engineering and Communications Technologies* (Vol. 162). https://doi.org/10.1007/978-3-031-26633-1_6
- Provost, F., & Fawcett, T. (2013). Data Science and its Relationship to Big Data and Data-Driven Decision Making. *Big Data*, 1(1). <https://doi.org/10.1089/big.2013.1508>
- Rivera Camargo, M. (2019). *Impacto de la educación superior en el desarrollo socio-económico de Colombia*.

<https://repository.unimilitar.edu.co/bitstream/handle/10654/21408/RiveraCamargoMaribel2019.pdf?sequence=1>

Sajid, S., Haleem, A., Bahl, S., Javaid, M., Goyal, T., & Mittal, M. (2021). Data science applications for predictive maintenance and materials science in context to Industry 4.0. *Materials Today: Proceedings*, 45, 4898–4905. <https://doi.org/10.1016/j.matpr.2021.01.357>

SAP. (2023). *Definición de machine learning en detalle*. <https://www.sap.com/latinamerica/products/artificial-intelligence/what-is-machine-learning.html>

Schwaber, K. (2004). *Agile Project Management with Scrum*. Microsoft Press. <https://ptgmedia.pearsoncmg.com/images/9780735619937/samplepages/9780735619937.pdf>

Seiffert, C., Khoshgoftaar, T. M., Van Hulse, J., & Napolitano, A. (2010). RUSBoost: A Hybrid Approach to Alleviating Class Imbalance. *IEEE Transactions on Systems, Man, and Cybernetics - Part A: Systems and Humans*, 40(1), 185–197. <https://doi.org/10.1109/TSMCA.2009.2029559>

Shirinbab, S., Lundberg, L., & Casalicchio, E. (2020). Performance evaluation of containers and virtual machines when running Cassandra workload concurrently. *Concurrency and Computation: Practice and Experience*, 32(17). <https://doi.org/10.1002/cpe.5693>

Srivastava, G., Muneeswari, S., Venkataraman, R., Kavitha, V., & Parthiban, N. (2022). A review of the state of the art in business intelligence software. In *Enterprise Information Systems* (Vol. 16, Issue 1, pp. 1–28). Taylor and Francis Ltd. <https://doi.org/10.1080/17517575.2021.1872107>


Superintendencia Nacional de Educación Superior Universitaria. (2021). *III Informe bienal sobre la realidad universitaria en el Perú*. Sunedu. <https://cdn.www.gob.pe/uploads/document/file/3018068/III%20Informe%20Bienal.pdf>

Suzanne Worthman, S. (2020). Las políticas de equidad educativa a nivel superior: Una propuesta de marco de análisis. *La-Melaua – Revista de Ciencias Sociales* <https://dialnet.unirioja.es/servlet/articulo?codigo=7544670>


- Sutherland, J. (2014). *The Art of Doing Twice the Work in Half the Time*. Crown Business.
https://www.agileleanhouse.com/lib/lib/News/More_Praise_for_Scrum_The_Art_of_Doing_T.pdf
- Tapasco Alzate, O. A., Ruiz Ortega, F. J., Osorio García, D., & Ramírez Ramírez, D. (2019). Deserción estudiantil: incidencia de factores institucionales relacionados con los procesos de admisión. *Educación y Educadores*, 22(1), 81–100.
<https://doi.org/10.5294/edu.2019.22.1.5>
- Vahid Mirjalili, S. R. (2019). *Python Machine Learning* (3rd ed.). Marcombo.
- Vanderplas, J. T. (2017). *Python data science handbook : essential tools for working with data*. O'Reilly Media.
- Vilela, P., Sánchez, J., & Chau, C. (2021). Challenges for higher education in Peru during the COVID-19 pandemic. *Desde El Sur*, 13, 1–11. <https://doi.org/10.21142/DES-1302-2021-0016>
- Wickham, H., & Grolemund, G. (2017). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media. www.allitebooks.com
- Yanto, B., Sudaryanto, A., & Hasri Ainun Pratiwi. (2023). Data Visualization Analysis of Waste Production Volume in Every District of Tangerang Regency in 2021 Using Looker Studio and Big Query Platforms. *JOURNAL OF ICT APPLICATIONS AND SYSTEM*, 2(1), 35–40. <https://doi.org/10.56313/jictas.v2i1.239>
- Yousif, O. S., & Zakaria, R. (2022). *Web-Based Big Data Integration Visualisation Solutions*. <https://doi.org/10.1108/s2040-726220220000026009>
- Zárate Rueda, R., & Mantilla Pinilla, E. (2014). *La deserción estudiantil UIS, una mirada desde la responsabilidad social universitaria*. <http://www.giselasavdie.com/when-abstract-hits-concrete.html>
- Zheng, A., & Casari, A. (2018). *Feature Engineering for Machine Learning: Principles and Techniques for Data Scientists*. O'Reilly Media.

6 ANEXOS

6.1 ANEXO 1



6.2 ANEXO 2



6.3 ANEXO 3

VARIABLE	TIPO_D ATO	TIPO_VARI ABLE	CATEGORIA_VARIA BLES	DEFINICION
ID_ESTUDIANTE	INT	NUMERICA	SIN CATEGORIA	ID DEL ESTUDIANTE PARA AREA DE FINANZAS
PERIODO	INT	NUMERICA	SIN CATEGORIA	CICLO DE PREGRADO
GENERO	VARCHA R	CATEGORIC A	INFORMACION_ESTUDI ANTIL_RANK	GENERO DE ESTUDIANTE
SEDE	VARCHA R	CATEGORIC A	INFORMACION_ESTUDI ANTIL_RANK	SEDE DEL ESTUDIANTE
EDAD_MATRICULA	INT	NUMERICA	EDAD_RANK	EDAD DEL ESTUDIANTE
CREDITOS_ESTUDIANT E	INT	NUMERICA	INFORMACION_ESTUDI ANTIL_RANK	CREDITOS DEL ESTUDIANTE
DIAS_TRANSCURRIDOS_ ASISTENCIA	INT	NUMERICA	ASISTENCIA_RANK	NUMEROS DE DIAS CONSECUTIV OS QUE UN ESTUDIANTE NO ASISTE A CLASE
CANTIDAD_CURSOS_AC TUALES	INT	NUMERICA	ACADEMICO_ACTUAL_ RANK	NUMERO DE CURSOS MATRICULAD OR DEL ESTUDIANTE
PROM_FINAL_NOTA_AN TERIOR	DOUBLE	NUMERICA	ACADEMICO_ANTERIOR _RANK	PROMEDIO FINAL DEL CICLO ANTERIOR DEL ESTUDIANTE
RATIO_CURSO_BICA_A NTERIOR	DOUBLE	NUMERICA	ACADEMICO_ANTERIOR _RANK	RATIO DE CURSOS JALADOS DEL CICLO ANTERIOR DEL ESTUDIANTE

REAL_FULL	DOUBLE	NUMERICA	BOLETAS_RANK	SUMA DE TODAS LAS BOLETAS DEL ESTUDIANTE
ANIO_FIN_COLEGIO	INT	NUMERICA	ANIO_FIN_COLEGIO_RANK	AÑO QUE ACABO EL COLEGIO EL ESTUDIANTE
CANAL_VENTA	VARCHAR	CATEGORICA	CANAL_VENTA_RANK	CANAL DONDE SE REALIZO LA COMUNICACIÓN CON EL ESTUDIANTE
CONTACTIBILIDAD_VENTA	INT	NUMERICA	CONTACTIBILIDAD_RANK	NUMERO DE VECES QUE SE LOGRO CONTACTAR A ESTUDIANTE HASTA QUE REALIZO EL PAGO
DURACION_CARRERA	INT	NUMERICA	DURACION_CARRERA_RANK	ENCUESTA ENVIADA AL ESTUDIANTE EN CUANTOS AÑOS TIENE APROXIMADAMENTE PRETENDE ACABAR LA CARRERA
DIAGNOSTICO	VARCHAR	CATEGORICA	DIAGNOSTICO_RANK	ENCUESTA ENVIADA AL ESTUDIANTE ASPECTO PSICOLOGICOS DEL ESTUDIANTE