



Universidad Continental

AVANCE DEL PROYECTO:

"Sistema predictivo basado en Machine Learning y Edge Computing para la prevención de la deserción escolar en la I.E.I. N° 32857 de Huacalle"

ASIGNATURA: TALLER DE INVESTIGACIÓN I
DOCENTE: DR. MAGLIONI ARANA CAPARACHIN

01

ARTICULO 01



AUTOR: HERNÁN H. HUAMÁN ARRATIA.

TÍTULO: MODELO PREDICTIVO PARA LA PREVENCIÓN DE LA DESERCIÓN ACADÉMICA EN ESTUDIANTES DE UN INSTITUTO TECNOLÓGICO DE PUNO.

REVISTA: JOURNAL OF SCIENTIFIC AND TECHNOLOGICAL RESEARCH INDUSTRIAL (JSTRI).

VOLUMEN: VOL. 6 N.º 2.

PÁGINAS(AÑO): 35 – 58(2025).

ESTADO DE ARTE QUE HACE EL AUTOR

Cita un estudio en la Universidad Pedagógica y Tecnológica de Colombia (UPTC) que implementó algoritmos predictivos con datos sociodemográficos y académicos. Menciona una investigación en la Unidad Educativa "Los Andes" durante el COVID-19, la cual concluyó que los factores socioeconómicos (falta de tecnología y apoyo familiar) fueron los determinantes principales de la deserción que el modelo logró predecir.

MOTIVACIÓN DEL AUTOR

El autor critica que las soluciones aplicadas hasta ahora para combatir la deserción no han resultado efectivas porque son reactivas. El problema requiere anticipación mediante nuevas fórmulas tecnológicas, no solo reacciones posteriores. El autor advierte que la región de Puno enfrenta desafíos mucho más complejos: alta tasa de pobreza, dispersión geográfica, falta de redes de apoyo y carencias materiales para el transporte o acceso tecnológico.

DESCRIPCIÓN DEL APORTE DEL AUTOR

Construyó un modelo de Machine Learning analizando una base de datos histórica de 4,424 estudiantes y 35 variables (académicas, sociodemográficas y macroeconómicas como el PIB y la inflación). Aplicó algoritmos como Regresión Logística, Árboles de Decisión y Máquinas de Vectores de Soporte, logrando optimizar un modelo de Bosques Aleatorios (Random Forest) que alcanzó altos niveles de precisión y recordación para clasificar a los alumnos en riesgo.

PROCESO PARA OBTENER EL APOORTE QUE CONSIDERA EL AUTOR

Analizó una base de datos histórica, reduciendo 35 variables originales a 14 variables predictoras clave (académicas, demográficas y financieras). Además, realizó conversiones numéricas de las variables categóricas para que pudieran ser procesadas por el algoritmo. Evaluó múltiples algoritmos de clasificación supervisada sin escalamiento de variables, incluyendo Regresión Logística, Descenso de Gradiente Estocástico, Naive Bayes y K-Vecinos más cercanos (KNN).

PROCESO PARA RESOLVER EL PROBLEMA CONSIDERADO POR EL AUTOR

A los alumnos marcados en riesgo por el sistema se les asignaron tutorías individualizadas, sesiones de refuerzo en materias críticas (matemáticas y física) y un seguimiento mediante informes mensuales de rendimiento. Para enfrentar los factores socioeconómicos detectados, se propuso un programa de préstamo de laptops y tablets, el fortalecimiento de la plataforma virtual y la reducción de la carga académica (menos cursos) en los primeros semestres.

MÉTRICAS QUE EL AUTOR USA Y EL RESULTADO QUE OBTIENE

Para evaluar matemáticamente a los algoritmos, el autor utilizó la métrica de Accuracy (Precisión general) sin validación y con validación cruzada estratificada de 10 particiones . Además, utilizó métricas de evaluación específicas para clasificación: Precision (Precisión macro), Recall (Recuperación macro) y F1-Score (Puntuación F1 macro).

OBSERVACIONES Y/O CRÍTICAS SUYAS AL ARTÍCULO

01

Para empezar con lo positivo, el estudio hace un trabajo muy serio al no quedarse solo con el primer resultado. Me parece muy rescatable que el autor no se conformó con probar un solo algoritmo, sino que comparó varios hasta comprobar que el Random Forest era el más adecuado.

02

El autor recomienda implementar este modelo en un instituto de Puno, pero ignora por completo la infraestructura tecnológica.

MATRIZ DE OPERACIONALIZACIÓN

Variables	Dimensiones	Indicadores	Instrumentos
Variable independiente: Modelo Predictivo basado en Aprendizaje Automático (Machine Learning)	Rendimiento Predictivo del Algoritmo	Precisión general	- Ficha de Registro de Datos - Algoritmo Predictivo - Cuestionario de Validación
		Precisión macro	
	Optimización del Modelo	Recuperación o Sensibilidad	
		Puntuación F1	
Variable dependiente: Riesgo de Deserción Académica	Dimensión Académica	Rendimiento académico en el primer semestre.	
		Tasa de asistencia a clases.	
	Dimensión Sociodemográfica Dimensión Económica / Financiera	- Edad del estudiante al momento de ingresar. - Género.	
		- Nivel de ingresos familiares. - Situación laboral del estudiante (si trabaja y estudia).	

ARTICULO 02

Revista Innovación y Software
Vol. 2, No. 2, Mes Septiembre-Febrero, 2021
ISSN: 2708-0935
Pág. 6-13
<https://revistas.ulasalle.edu.pe/innosoft>

Tipo de artículo: Artículos cortos
Temática: Inteligencia artificial
Recibido: 05/04/2021 | Aceptado: 08/06/2021 | Publicado: 30/09/2021

Identificadores persistentes:
ARK: [ark:/42411/s6/a40](https://nbn-resolving.org/urn:nbn:org:ark:42411-s6-a40)
PURL: [42411/s6/a40](https://nbn-resolving.org/urn:nbn:org:ark:42411-s6-a40)

Modelo predictivo para la detección temprana de estudiantes con alto riesgo de deserción académica

Predictive model for the early detection of students with high risk of academic dropout

Kevin Rivera Vergaray ¹[\[ORCID: 0000-0001-5391-4352\]](mailto:kevin.rivera1@unmsm.edu.pe)*

¹ Universidad Nacional Mayor de San Marcos, Huaraz-Perú. kevin.rivera1@unmsm.edu.pe

* Autor para correspondencia: kevin.rivera1@unmsm.edu.pe

Resumen

Se comparan los resultados de 4 modelos predictivos, de regresión logística, árboles de decisión, KNN y una red neuronal para predecir la deserción académica de estudiantes en la Universidad Nacional Intercultural de la Amazonia, aplicado a un dataset extraído de la base de datos del sistema de gestión académica de la universidad, que contiene datos socioeconómicos y de rendimiento académico los cuales fueron procesados y formateados utilizando técnicas de onehotencoding para así poder aplicar los modelos predictivos ya mencionados. Para el procesamiento y formateo de datos se utilizó consultas Transac Sql y la aplicación de los modelos predictivos se hizo a través del Software Knime y utilizando Python a través de Google Colab. Los resultados obtenidos al aplicar 4 modelos predictivos son muy buenos ya que todos superaron el 80% de Accuracy, lo cual garantiza que puedan ser puestos en producción para el beneficio de la universidad y así pueda tomar mejores decisiones a la hora de abordar la deserción académica. Se concluye que aplicar un modelo predictivo en las universidades para la detección temprana de estudiantes con alto riesgo de deserción académica es viable y muy beneficioso para que las universidades a través de sus gestores académicos puedan aplicar estrategias mas focalizadas para reducir sus índices de deserción académica.

Palabras clave: Deserción académica, Modelo predictivo, Dataset.

Abstract

The results of 4 predictive models, logistic regression, decision trees, KNN and a neural network are compared to predict the academic dropout of students at the National Intercultural University of the Amazon, applied to a dataset extracted from the system's database. of academic management of the university, which contains socioeconomic and academic performance data which were processed and formatted using onehotencoding techniques in order to apply

AUTOR: KEVIN RIVERA VERGARAY

TÍTULO: MODELO PREDICTIVO PARA LA DETECCIÓN TEMPRANA DE ESTUDIANTES CON ALTO RIESGO DE DESERCIÓN ACADÉMICA 2025.

REVISTA: REVISTA INNOVACIÓN Y SOFTWARE

VOLUMEN: VOL. 2, NO. 2

PÁGINAS(AÑO): 6-13(2021).

ESTADO DE ARTE QUE HACE EL AUTOR

El autor establece que la deserción estudiantil universitaria es un fenómeno mundial que posee múltiples variables y no es una preocupación exclusiva del ámbito académico. El autor fundamenta su investigación describiendo cuatro algoritmos de Machine Learning: Regresión Logística (útil para variables dependientes dicotómicas), Árboles de Decisión (usados para establecer reglas de clasificación y segmentación), K-Nearest-Neighbor o KNN (algoritmo basado en instancias para buscar puntos de datos similares) y Redes Neuronales Artificiales (modelos que imitan la estructura del sistema nervioso).

MOTIVACIÓN DEL AUTOR

La motivación principal radica en las graves consecuencias de la deserción, la cual genera que alumnos con educación incompleta se incorporen al mundo laboral como subempleados, perjudicando al estudiante, a su familia, al país y al presupuesto de la propia universidad. El autor observa un problema específico en la Universidad Nacional Intercultural de la Amazonía (UNIA), donde el 40% de los estudiantes son indígenas y el 60% son mestizos, pero no cuentan con información procesada sobre las deserciones por semestre académico.

DESCRIPCIÓN DEL APORTE DEL AUTOR

El autor construyó y formateó un dataset real extrayendo datos socioeconómicos y académicos de la base de datos de la UNIA utilizando consultas Transac SQL y técnicas de onehotencoding. Aplicó, evaluó y comparó cuatro modelos predictivos utilizando el software KNIME y Python a través de Google Colab. El autor demostró matemáticamente que los modelos KNN y Árbol de Decisión son los que mejor se ajustan a los datos, obteniendo un Accuracy (precisión) destacable de 88.844% y 88.40% respectivamente.

PROCESO PARA OBTENER EL APORTE QUE CONSIDERA EL AUTOR

El autor extrajo la información directamente de la base de datos del sistema de gestión académica de la Universidad Nacional Intercultural de la Amazonía (UNIA). Para lograrlo, ejecutó consultas Transac SQL , con lo cual construyó un dataset que contenía registros históricos desde el año 2005

PROCESO PARA RESOLVER EL PROBLEMA CONSIDERADO POR EL AUTOR

Para predecir el riesgo de deserción académica, el autor probó y comparó cuatro modelos predictivos de Machine Learning: Regresión Logística, Árboles de Decisión, KNN (K-Nearest-Neighbor) y una Red Neuronal. El proceso de aplicación y entrenamiento de estos modelos sobre el dataset procesado se realizó utilizando dos entornos tecnológicos: el software KNIME y programación en Python mediante la plataforma Google Colab. Finalmente, el autor comparó el rendimiento de los cuatro algoritmos para identificar cuál describía un mayor ajuste a los datos.

MÉTRICAS QUE EL AUTOR USA Y EL RESULTADO QUE OBTIENE

Para evaluar exhaustivamente el desempeño de sus modelos predictivos, el autor utilizó un conjunto de seis métricas de evaluación de Machine Learning: Accuracy, Error, Recall, Precision, Sensitivity, Specificity. El resultado general fue muy exitoso, ya que el autor logró que los cuatro modelos predictivos superaran el 80% de Accuracy (Exactitud). Al comparar los resultados, determinó que los mejores algoritmos para este problema fueron KNN y el Árbol de Decisión.

OBSERVACIONES Y/O CRÍTICAS SUYAS AL ARTÍCULO

01

Rivera menciona que procesó sus algoritmos utilizando Google Colab. Aunque es una herramienta excelente, Colab es un entorno 100% basado en la nube (Cloud Computing) que requiere una conexión a internet estable y de banda ancha para procesar los datos en los servidores de Google. Esta metodología hace que el modelo de Rivera sea inaplicable en entornos rurales o con brecha digital

02

El artículo de Rivera termina concluyendo que "los gestores académicos deberían aplicar estos modelos". Sin embargo, su aporte se queda en un script de código en Python y KNIME. Un director de colegio o un auxiliar (como los de la I.E.I. N° 32857) no saben programar en Python ni ejecutar un entorno de Machine Learning.

MATRIZ DE OPERACIONALIZACIÓN

Variables	Dimensiones	Indicadores	Instrumentos
Variable Independiente (VI): Modelos predictivos de Machine Learning	Desempeño predictivo de los algoritmos	<i>Accuracy</i> (Exactitud global). Tasa de Error. <i>Precisión</i> (Precisión). <i>Recall / Sensitivity</i> (Sensibilidad). <i>Specificity</i> (Especificidad)	Matriz de Confusión. Software KNIME. Entorno de programación Google Colab (Python).
Variable Dependiente (VD): Deserción académica universitaria	Dimensión Académica	Variables de rendimiento académico (Extraídas del sistema, ej. notas, cursos).	Análisis documental / Extracción de base de datos (Consultas Transac SQL)
	Dimensión Socioeconómica	Variables de origen y situación económica (Extraídas del sistema).	Análisis documental / Extracción de base de datos (Consultas Transac SQL).
	Estado final del estudiante (Target)	Condición actual (Activo o Desertor).	Base de datos del Sistema de Gestión Académica de la UNIA